CentraleSupélec

Challenge

# IA culturelles

Compar:IA

Raphaël VIGNAL, Maëlys HANOIRE,
Gaël GARNIER, Fanny BADOULES

# Sommaire


Introduction

1. Hypothèse de la mesure de créativité
2. Fiabilité des jugements humains
    1. Accord sur le signal « créative »
    2. Biais de sélection des votants
3. Classement par le modèle Bradley-Terry
    1. Description du modèle
    2. Transitivité stochastique
4. Biais systématiques dans les données
    1. Biais de longueur
    2. Proposition d'annotation amélioré
5. Proposition de réponse
    1. CI
    2. Pipeline de la suite du projet

Conclusion

# Introduction

# Introduction

**Quelle place le contenue et l'offre culturelle français ont dans les réponses des IA conversationnelle ?**

## Enjeux

Avoir des modèles respectueux de la pluralité des expressions culturelles (respect du droit d'auteur…)

## Objectifs

Mieux comprendre usage de l'IA générative

Explorer les biais et performances des modèles sur des contenus culturels

## Méthodologie

Modélisation de la « créativité » d'un modèle d'IA sur des contenus culturels

CentraleSupélec

# 1

# Hypothèse

# Hypothèse

Mesure de la créativité :

- CI : Creativity Index = $\alpha$ Nouveauté + $\lambda$ Valeur + $\gamma$ Surprise
- Avec $\lambda > \alpha > \gamma$

Justification :

- Littérature (Amabile, Boden) : la valeur domine dans le jugement expert
- Si les votants Compar:IA se comportent comme des experts $\lambda$ dominant attendu

**Les données Compar:IA permettront-elles de confirmer cette pondération ?**

# 2.1

# Fiabilité des jugements humains

## Accord sur le signal « créative »

# Accord sur le signal « créative »

| Métrique | K de Cohen | Niveau d'accord |
|---|---|---|
| useful | 0.36 | Accord passable (0.21–0.40) |
| complete | 0.29 | Accord passable (0.21–0.40) |
| creative | 0.31 | Accord passable (0.21–0.40) |

Hypothèse 1:

- Plus de prompt appelant à l'utilité qu'à la créativité

Hypothèse 2:

- La créativité est une notion fortement subjective (culture,expérience)

CentraleSupélec

# 2.2

# Fiabilité des jugements humains

## Biais de sélection des votants

# Biais de sélection des votants

<u>Représentativité de corpus voté :</u>

153 062 conversations votées sur 472 334 au total -> seulement 32 %

| | Non votées | Votées |
|---|---|---|
| Nombre | 319 272 | 153 062 |
| % du corpus | 68% | 32% |

Le classement des modèles repose sur moins d'un tiers des conversations.

# Biais de sélection des votants

Biais observés :

| | Non votées | Votées | Biais ? |
|---|---|---|---|
| Nombre de tours (médiane) | 1 tour | 1 tour | Non |
| Nombre de tokens (médiane) | 1 212 | 1 554 | Oui (+28%) |
| Catégories | Distribution uniforme | Déséquilibre | Oui |

Le classement sur-représente les échanges longs et sous-représente certains thèmes.

# 3.1

# Classement par Bradley-Terry

## Description du modèle

# Classement par Bradley-Terry

*Approche probabiliste pour comparer des éléments*

**Objectif:**

- Comparer 105 modèles LLM à partir de comparaisons par paires.

**Principe:**

- Hypothèse que chaque élément *i* a un score de force latente nommé β.
- β détermine la probabilité de *i* de "*battre*" *j*.

$$P(i \text{ bat } j) = \frac{\beta_i}{\beta_i + \beta_j}$$

**Méthode:**

- Algorithme MM (Zermelo)
- Convergence en ~ 25 itérations

**Résultat:**

- Un vecteur de score $\beta \in R^n$ induisant un classement total sur les *n* éléments comparés.

# Classement par Bradley-Terry

## Préparation du dataset (Global)

- 162,858 → 98,782 votes retenus
- 105 modèles
- Graph fortement connexe pour Bradley-Terry
- Suppressions :
  - ex-aequos (31%),
  - sans préférence (8%),
  - self-comparaisons (237)

# Classement par Bradley-Terry

Classement Global (98 782 votes)

- Estimations les scores de force β i
- Par MLE via l'algorithme itératif de *Zermelo* (*MM Algorithm*).
- Convergence du modèle.

*On constate une domination des modèles Mistral et Gemini dans le classement global.*

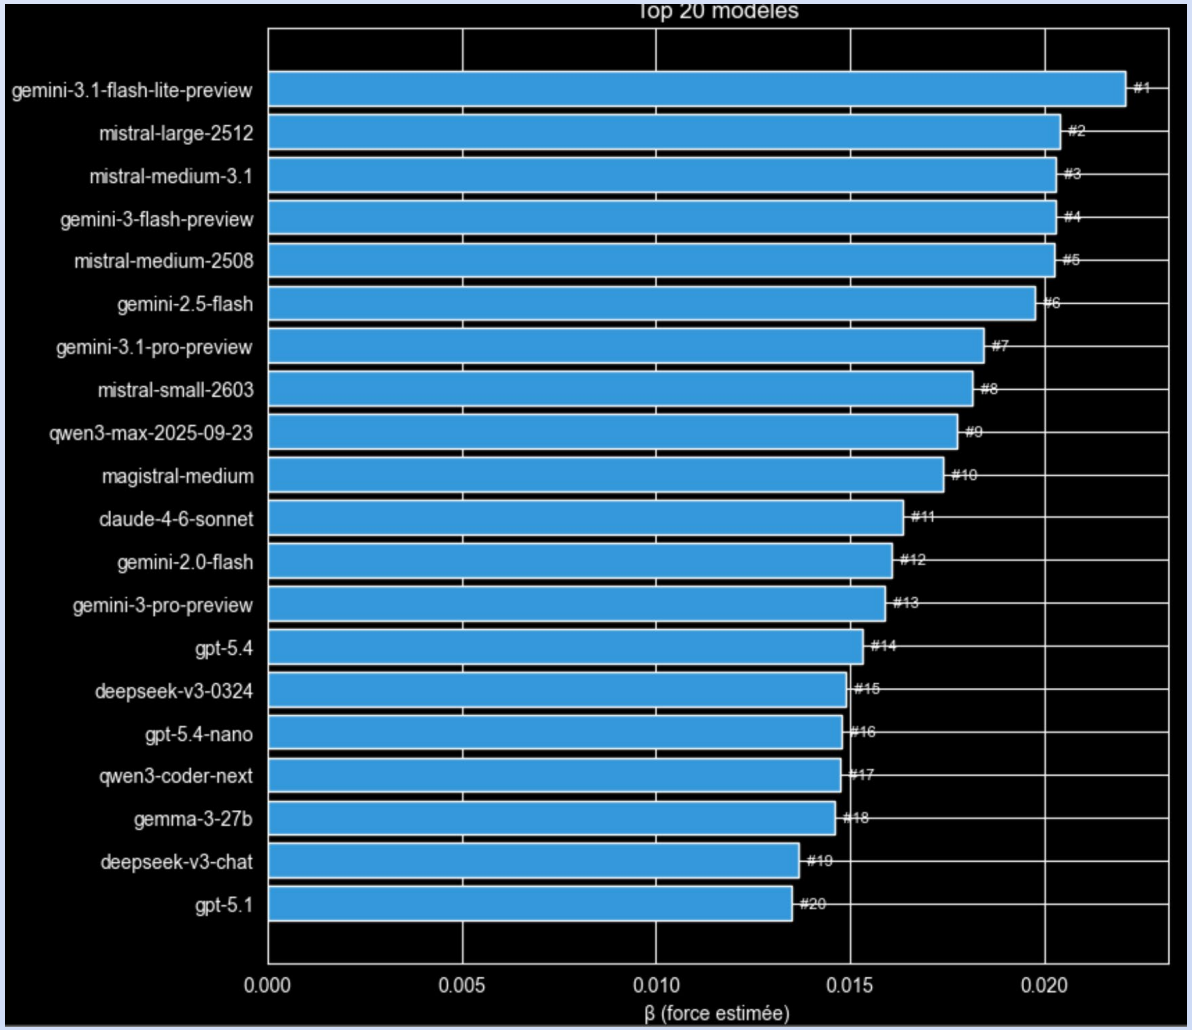

# Classement par Bradley-Terry

Comparaison Créativité (8065 votes) :

- Uniquement les conversations *conv_creative_a* || conv_creative_b
- 8.2% du total des votes
- 102/105 modèles
- Graph fortement connexe

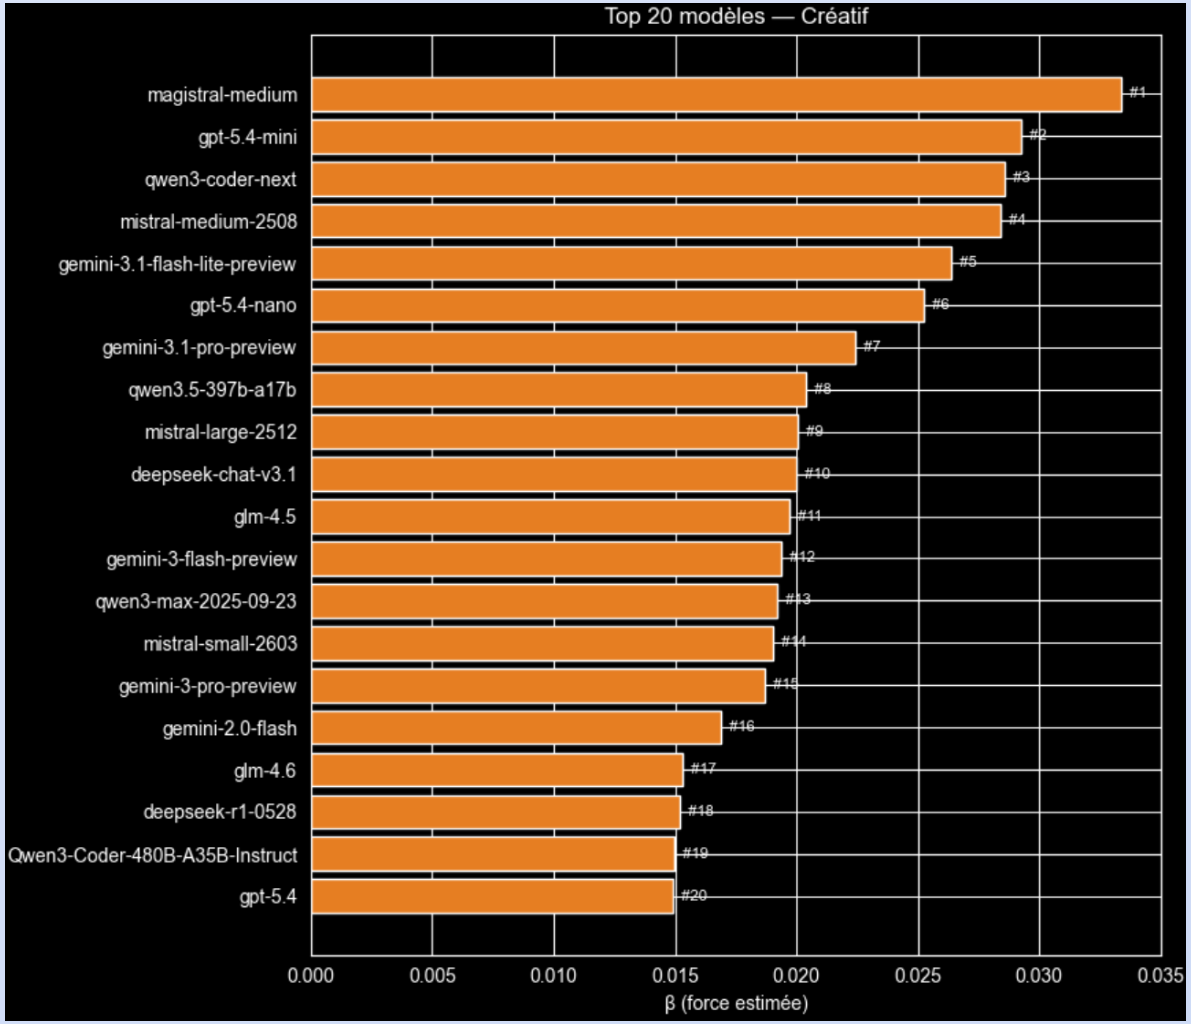


*Ordre significativement différent. Magistral-medium présente une dominance significative. Arrivée des modèles raisonnants.*

# Classement par Bradley-Terry

## Corrélation de Spearman

- Calcul de la corrélation entre le rang global et le rang créativité.

## Résultats :

- **ρ** = 0.881
- p-value ~ 3.32e-34 < 0.05
- Interprétation
  - Corrélation de Spearman forte
  - p-value test l'hypothèse Ho : ρ = 0 (pas de corrélation)
  - On rejette Ho avec une grande confiance

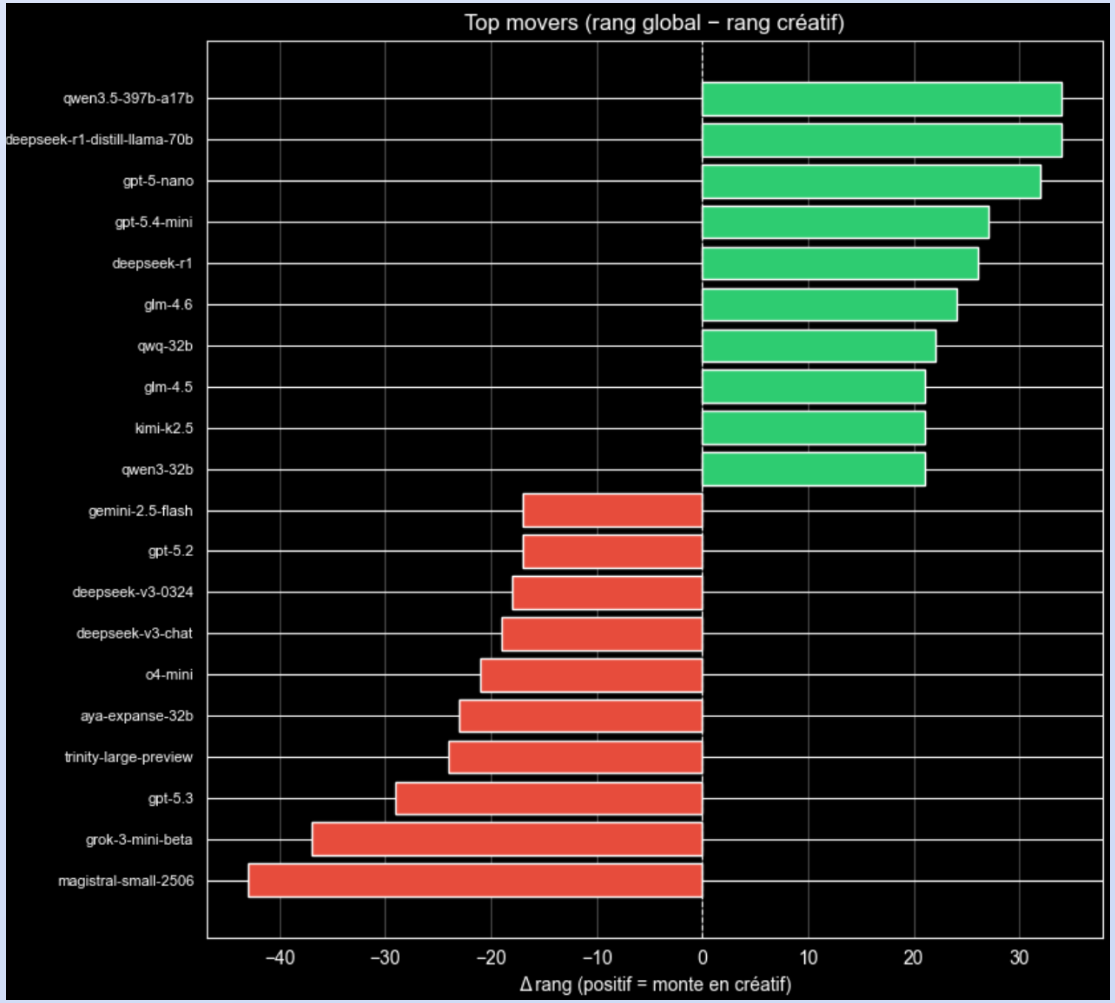

# 3.2

# Classement par Bradley-Terry

## Transitivité stochastique

# Transitivité stochastique

Contexte :

- BT calcule score de force β pour chaque modèle
- Pour toute paire même jamais affrontée directement :

$$P(A \text{ bat } B) = \sigma(\beta A - \beta B)$$

Justification par la transitivité stochastique :

- Si $P(i \text{ bat } j) \geq 0.5$ et $P(j \text{ bat } k) \geq 0.5$,
  alors on doit avoir $P(i \text{ bat } k) \geq \max(P(i \text{ bat } j), P(j \text{ bat } k))$
- Vérifié par construction mathématiques

# Transitivité stochastique

Limite test de puissance :

- Combien de matchs faudrait-il pour confirmer statistiquement P(i bat k) ?

Modèle Davidson

310 matchs pour distingué gemma-3-27b et claude-4-5-sonnet

- Données sont insuffisantes pour confirmer les différences entre modèles proches

Classement de la créativité moins tranché qu'il n'y paraît :

- Classement est mathématiquement cohérent mais statistiquement fragile
- Indécision des votants (critères de choix instable)
- Biais culturel faible (pas de données d'entrainement culturellement différentes)

# 4.1

# Biais systématiques

## Biais de longueur

# Biais de Longueur

Corrélation :

- Déterminer la corrélation entre la différence de longueur des sorties et le choix de l'utilisateur
- P value=0.01 (<0.05 significatif)
- Faible corrélation positive (0.1)

$$r = \frac{n\sum xy - \sum x \sum y}{\sqrt{(n\sum x^2 - (\sum x)^2)(n\sum y^2 - (\sum y)^2)}}$$

Régression Logistique :

- Accuracy de 0.61/0.65 et poids de la co-variable faible (0.0001)

Classement Bradley-Terry:

- Minimiser le score de Bradley-Terry des modèles trop verbeux
- Changement important dans le top 10

# 4.2

# Biais systématiques

## Protocole d'annotation amélioré

# Protocole d'annotation amélioré

L'objectif est de réduire 3 biais :

- Biais de position
- Biais de longueur
- Biais de sélection (catégories)

→ Sans augmenter le taux d'abandon de plus de 15%.

Idée : Agir sur l'interface utilisateur et conserver les corrections statistiques

# Protocole d'annotation amélioré

Solutions proposées :

| Biais | Solution | Détail | Impact UX |
|---|---|---|---|
| Position | Randomisation A/B | Ordre des réponses aléatoire | Aucun |
| Longueur | Troncature + indicateur | Affichage tronqué + nombre de mots | Faible |
| Catégories | Suggestions de prompts | Mise en avant de prompts sous-représentés | Neutre voire positif |

Protocole plus robuste sans dégrader l'engagement utilisateur.

# 5.1

# Proposition de réponse

CI

# Creativity Index

| CI | Problèmes rencontrés | Métrique choisie | Explication |
|---|---|---|---|
| Nouveauté | Biais de longueur | MATTR | Diversité lexicale normalisée sur fenêtres fixes |
| Valeur | Paradoxe du juge | BERTScore | Similarité entre la réponse et le prompt |
| Surprise | Critère instable (transitivité stochastique) | Divergent Thinking Score | Distance sémantique entre concepts (cf. idées éloignées) |

Mesure de la créativité :

- CI : Creativity Index = $\alpha$ Nouveauté + $\lambda$ Valeur + $\gamma$ Surprise
- Avec $\alpha > \gamma > \lambda$

Hypothèse invalidée

Validation de l'index :

- Bradley-Terry sur les scores CI et vérification transitivité stochastique

# 5.2

# Proposition de réponse

## Pipeline de la suite du projet

# Pipeline de la suite du projet

**But du ministère de la culture :**
IA culturelles et responsables

**Tâche demandée :**
Mesure de la créativité pour évaluer place du contenu culturel français

**Problème observé :**
Biais culturel faible (cf. modèles entraînés sans distinction de données culturelles)
La mesure de créativité globale ≠la diversité culturelle

**Mise en contexte possible :**

Entraîner un modèle sur un dataset culturellement français

Évaluer la créativité (due aux données) via notre CI sur une interface débiaisée

Pondération calibrée avec des experts

# Conclusion

# Conclusion

## Enjeux

Place de la culture française dans les LLM

## Objectifs

Mesurer la créativité

Proposition de CI

Révélation de biais et limites du dataset

## Méthodologie

BT + Davidson

MATTR

BERTScore

DTS

CentraleSupélec

Merci pour votre attention
Place aux questions !

https://github.com/fannnyyy/Measure_creativity_LLM